

深度学习辅助的 OFDM 信道估计：公平基线、物理先验与泛化分析

英文标题：Deep Learning-Aided OFDM Channel Estimation: Fair Baselines, Physical Priors, and Generalization

1. 问题定位与可复现实验链路

本项目实现的是传统 OFDM 接收链路中的深度学习辅助信道估计模块，不是端到端 learned receiver。处理链路为：

```
bits -> 16QAM -> pilot/data/guard/DC mapping -> unitary IFFT + CP  
-> block Rayleigh FIR + AWGN -> CP removal + unitary FFT  
-> channel estimation -> one-tap ZF/MMSE -> hard demapping -> BER/SER/EVM
```


频域模型为 $Y[k] = H[k]X[k] + w[k]$ 。IFFT 使用 $\text{ifft}(X) \cdot \sqrt{N}$ ，FFT 使用 $\text{fft}(x) / \sqrt{N}$ ；每个 Rayleigh 信道 realization 都归一化到 $\sum |h[l]|^2 = 1$ ，且 CP=16 不小于最大信道长度。SNR 始终按信道输出的经验平均功率定义： $\text{noise_power} = \text{mean}(|\text{channel_output}|^2) / 10^{(\text{SNR_dB}/10)}$ 。训练、验证和评测共用同一帧生成路径，因此这里的 SNR 不是直接的 E_b/N_0 。

正式压力测试采用 FFT=64、14 个 OFDM 符号、16QAM、两侧 8 个 guard、1 个 DC null、12-tap 指数 PDP，并在 0--30 dB 评估。每个方法在同一帧复用完全相同的比特、信道与 AWGN realization；没有为了 CNN 调整测试数据或弱化基线。

2. Staggered 导频的物理含义

每个符号仅有 6--7 个 pilot，帧内合计 97 个观测，导频开销为 12.60%。55 个有效子载波在整帧的 pilot 并集覆盖率为 100%，每个有效子载波平均被直接观测 1.764 次。

因此，这不是“所有子载波均未观测的纯频域插值”任务，而是单符号稀疏 pilot、块衰落条件下的帧级观测融合和信道去噪实验。Frame-LS 先合并重复观测再插值；DFT-LS 对该帧级估计做有限时延投影；LMMSE 对相同帧级 LS 向量使用统计滤波；CNN 以同一帧级 LS 与 mask 为输入。信息量对所有强基线和 CNN 一致。



3. 方法与统计口径


比较 Perfect CSI、Frame-LS、DFT-LS、oracle LMMSE、训练先验 LMMSE、sample-covariance LMMSE 与残差 1-D CNN。CNN 用 circular dilated residual blocks 从帧级线性 LS 预测频域残差；其 hard delay projection 在训练和推理均使用同一有效 tap 区间。MMSE 输出在硬判决前去除幅度偏置，因此在该未编码单抽头模型中，同一信道估计下 ZF 与 MMSE 判决可重合，这是预期现象。

主结果的 95% CI 是 3 个独立测试 Monte Carlo seed 的 Student-t 区间。多模型 CNN 的 95% CI 则是 3 个独立 training/model seed 的 Student-t 区间，且每个模型都在同一 3 个测试 seed、每个 seed 60 帧上评估。测试随机性和模型训练随机性分别保存，不能把 3 个测试 seed 误写成 3 次独立训练。


4. 匹配分布结果

以下为单一正式 checkpoint 在 3 个测试 seed、每个 seed 100 帧上的 20 dB 主结果。

方法	BER (均值 +/- 95% CI)	信道 NMSE (均值 +/- 95% CI)
PerfectCSI+ZF	1.2100e-02 +/- 8.69e-04	0.0000e+00 +/- 0.00e+00
Frame-LS-linear+ZF	1.8493e-02 +/- 6.19e-04	4.7356e-02 +/- 7.67e-03
DFT-LS+ZF	1.8577e-02 +/- 7.14e-04	3.4018e-02 +/- 6.48e-03
LMMSE-oracle+ZF	1.3400e-02 +/- 1.01e-03	2.0500e-03 +/- 3.81e-04
ResidualCNN+ZF	1.4991e-02 +/- 1.54e-03	1.1124e-02 +/- 4.39e-04



Matched BER



Matched channel NMSE

在匹配的可解析统计模型中，CNN 优于简单 Frame-LS/DFT-LS 的部分工作点，但不优于 oracle LMMSE；高 SNR 还出现模型误差地板。该结论与已知 PDP/时延支持时 LMMSE 可利用准确二阶统计先验相一致。


5. 多训练 seed、实用 LMMSE 与泛化

sample-covariance LMMSE 使用有限历史信道样本估计均值与频域协方差，再通过 diagonal loading 与最小特征值截断正则化。其线上仅执行缓存矩阵 $\mathbf{K} @ \mathbf{H_LS}$ 。历史先验均来自 12-tap 指数 PDP，未从测试帧拟合：


先验	来源	历史信道样本数	协方差构建 (ms)
LMMSE-oracle	analytic:exponential:12	0	1.917
LMMSE-sample-100	sample:exponential:12	100	1.390
LMMSE-sample-1000	sample:exponential:12	1000	2.376
LMMSE-sample-10000	sample:exponential:12	10000	20.026

下表均为 20 dB。LMMSE/传统行的 CI 是测试 seed 变化；CNN 行的 CI 是模型训练 seed 变化，统计对象不同，不能将二者误解为同一层级的显著性检验。

场景	方法	BER (均值 +/- 95% CI)	NMSE (均值 +/- 95% CI)
匹配	DFT-LS+ZF	1.7946e-02 +/- 4.30e-03	2.8074e-02 +/- 8.21e-03
匹配	LMMSE-oracle+ZF	1.3255e-02 +/- 4.67e-03	2.0693e-03 +/- 5.37e-04
匹配	LMMSE-sample-10000+ZF	1.6481e-02 +/- 5.87e-03	4.8932e-03 +/- 1.04e-03
匹配	ResidualCNN-single+ZF	1.8857e-02 +/- 8.63e-04	2.7019e-02 +/- 2.79e-03
匹配	ResidualCNN-domain_randomized+ZF	1.8735e-02 +/- 1.75e-03	3.1954e-02 +/- 5.75e-03
8-tap 均匀失配	Frame-LS-linear+ZF	2.1062e-02 +/- 1.35e-03	1.0804e-01 +/- 1.39e-02
8-tap 均匀失配	LMMSE-train-prior+ZF	1.5158e-02 +/- 1.34e-03	1.9678e-03 +/- 2.72e-04
8-tap 均匀失配	LMMSE-sample-10000+ZF	1.8803e-02 +/- 1.30e-03	5.0519e-03 +/- 7.84e-04
8-tap 均匀失配	ResidualCNN-single+ZF	2.7710e-02 +/- 1.49e-03	7.2017e-02 +/- 1.17e-02
8-tap 均匀失配	ResidualCNN-domain_randomized+ZF	2.4661e-02 +/- 1.36e-03	5.6525e-02 +/- 3.39e-03
未见 10-tap 陡峭指数	LMMSE-sample-10000+ZF	1.3495e-02 +/- 1.45e-03	3.8605e-03 +/- 4.24e-04
未见 10-tap 陡峭指数	ResidualCNN-single+ZF	1.2384e-02 +/- 4.85e-04	9.8441e-03 +/- 1.01e-03
未见 10-tap 陡峭指数	ResidualCNN-domain_randomized+ZF	1.3982e-02 +/- 2.12e-03	2.3027e-02 +/- 7.77e-03



Practical comparison under matched statistics




Training-seed variability on the shared matched test set

结论：匹配分布下，single CNN 的 20 dB BER 为 $1.8857e-02$ ，domain-randomized CNN 为 $1.8735e-02$ ，均不优于 10,000 样本 practical LMMSE。8-tap uniform 失配下，domain randomization 将 CNN BER 从 $2.7710e-02$ 降至 $2.4661e-02$ ，但仍高于 practical LMMSE 的 $1.8803e-02$ 。在未见的 10-tap 陡峭指数 PDP 下，single CNN 的 BER 为 $1.2384e-02$ ，略低于 sample LMMSE 的 $1.3495e-02$ ，但其 NMSE 更高 ($9.8441e-03$ 对 $3.8605e-03$)；domain-randomized CNN 为 $1.3982e-02$ ，反而劣于 single CNN。因此 domain randomization 只对部分失配有帮助，且不能把不同 CI 统计层级的 BER 差直接解释为普适显著性结论。

6. Delay-domain prior 消融

四个模型训练预算、优化器、训练/验证/测试 seed 划分和网络宽度相同，仅改变残差连接与时延先验形式；每个变体训练 3 个独立模型。hard projection 的有效 tap indexing 由单元测试覆盖，投影长度严格等于配置的信道支持。

模型	BER (模型 seed CI)	总体 NMSE	pilot NMSE	data NMSE	deep-fade NMSE
Plain CNN	2.6751e-02 +/- 3.48e-03	5.4985e-02 +/- 1.38e-02	1.4081e-02 +/- 4.22e-03	1.3653e-02 +/- 3.82e-03	9.6911e-02 +/- 2.12e-02
Residual CNN	1.9999e-02 +/- 1.05e-03	4.0473e-02 +/- 2.25e-03	8.4430e-03 +/- 7.25e-04	8.1812e-03 +/- 7.12e-04	5.1818e-02 +/- 9.91e-03
Residual CNN + hard delay projection	2.0096e-02 +/- 9.38e-04	3.2435e-02 +/- 5.23e-03	7.7403e-03 +/- 9.05e-04	7.4369e-03 +/- 8.54e-04	5.7250e-02 +/- 6.79e-03
Residual CNN + soft delay regularization	2.0015e-02 +/- 1.05e-03	4.0462e-02 +/- 2.30e-03	8.4410e-03 +/- 7.90e-04	8.1785e-03 +/- 7.78e-04	5.1808e-02 +/- 9.78e-03




hard projection 把总体 NMSE 从 $4.0473e-02$ 降至 $3.2435e-02$ ，也改善 pilot/data 平均 NMSE；但 BER 从 $1.9999e-02$ 变为 $2.0096e-02$ ，其 Student-t 区间重叠，并且 deep-fade NMSE 从 $5.1818e-02$ 上升至 $5.7250e-02$ 。这说明总体信道 MSE 的降低不必然与硬判决最敏感子载波上的误差同步降低；项目不将 delay prior 描述为 BER 的全面提升。

7. 修正后的复杂度口径

固定 pilot pattern、PDP、信道长度和 SNR 时，LMMSE 离线构建协方差与 $\mathbf{K} = \mathbf{R}_{hp} \text{ inv}(\mathbf{R}_{pp} + \text{noise_cov})$ ，线上不再重复求逆。下表在同一 CPU、batch=64、5 次 warm-up、15 次重复测量下给出平均值与标准差。

估计器	离线协方差 / K 构建 (ms)	checkpoint 加载 (ms)	缓存后在线 (ms/帧)	存储 / 参数
Residual CNN	-	4.605	0.0620 +/- 0.0131	25858 参数， 1636352 MAC/帧， 113183 B checkpoint
Oracle LMMSE	1.917 / 0.396	-	0.0029 +/- 0.0008	0 可训练参数， K=124784 B
Sample LMMSE (10,000)	20.026 / 0.625	-	0.0032 +/- 0.0007	0 可训练参数， K=124784 B



8. 结论、边界与复现

1. CNN 在部分匹配工作点优于简单 LS/DFT-LS，但不优于 oracle LMMSE；匹配与 8-tap uniform 场景也不优于 sample-covariance LMMSE。未见陡峭指数 PDP 的 single CNN BER 略低、NMSE 更高，不能泛化为总体胜出。
 2. domain randomization 缩小了 8-tap uniform 失配下的差距，却未改善未见陡峭指数 PDP。
 3. hard delay projection 降低总体 NMSE，但未带来可分离的 BER 收益。项目的价值在于说明何时 CNN 有限有效、何时历史信道统计 LMMSE 更合适，而非预设 CNN 必胜。
- 边界：假设完美同步、帧内静态块衰落，不含 CFO、相位噪声、Doppler、IQ imbalance、功放非线性或信道编码。更复杂失配与硬件非理想仍需新实验验证。